\newpage

Kurzfassung

Bodenverdichtung, Wasserhaushalt und Nährstoffverfügbarkeit sind zentrale Steuergrößen für Pflanzenwachstum und Ertrag. Zur Charakterisierung der mechanischen Bodenverhältnisse wird in Forschung und Praxis der Soil Cone Penetrometer nach ASABE-Standard S313.3 eingesetzt. Parallel dazu hat sich die sichtbare und nahinfrarote Spektroskopie (Vis–NIR, ca. 350–2500 nm) als schnelles, nichtdestruktives Verfahren zur Bestimmung von Bodenwassergehalt, organischer Substanz und Nährstoffen etabliert.

Ziel dieses Projekts ist die Vorbereitung eines Systems, das einen normgerechten Penetrometer mit einem Vis–NIR-Spektrometer kombiniert. In der hier beschriebenen Phase wurden (i) das mechanisch-optische Konzept einer Penetrometerspitze mit integrierter Faseroptik ausgearbeitet, (ii) die Umsetzung mit der Werkstatt des ILT und externen Faseroptik-Herstellern abgestimmt, (iii) eine Patent- und Literaturrecherche zum Stand der Technik durchgeführt und (iv) ein Machine-Learning-Modell zur Vorhersage von Bodenwassergehalt **und Stickstoffgehalt** aus NIR-Spektraldaten entwickelt und optimiert.

Finale Ergebnisse der ML-Auswertung:

- **Wassergehalt (SVR):** $R^2 = 0{,}844$, MAE = 1,55 %, Genauigkeit ±5 % = 92,3 %
- **Stickstoff-Klassifikation (RandomForest + PCA):** Balanced Accuracy = **98,08 %** über 4 Klassen (0 / 75 / 150 / 300 mg N kg^{-1})
- **Verbesserung durch Feature Engineering:** +10 Prozentpunkte gegenüber 512-Wellenlängen-Baseline (88,1 %)
- **Sicherheitslayer:** OOD-Detektion, Konfidenzprüfung, Plausibilitätschecks

Die Ergebnisse demonstrieren, dass kombinierte Wassergehalt- und Stickstoffvorhersage aus einem einzigen 512-Pixel-NIR-Spektrum mit praxistauglicher Genauigkeit möglich ist.

\newpage

Einleitung

Hintergrund und Motivation

Präzisionslandwirtschaft erfordert räumlich und zeitlich hochaufgelöste Informationen über den Bodenstatus. Bodenwassergehalt und Nährstoffverfügbarkeit – insbesondere Stickstoff – sind zentrale Parameter für Bewässerungs- und Düngungsmanagement. Traditionelle Analysemethoden (Gravimetrie für Wasser, Nasschemie für Stickstoff) sind zeitaufwendig, destruktiv und zu kostspielig für flächendeckende Anwendungen.

Die nahinfrarote Spektroskopie (NIR, 700–2500 nm) bietet eine schnelle, nicht-destruktive Alternative: Ein Lichtstrahl tritt ins Bodenmaterial ein, wird reflektiert und enthält im Reflexionsspektrum Information über chemische Bindungen (O-H, N-H, C-H), die direkt mit Wassergehalt und organischer Substanz korrelieren. In Verbindung mit Machine-Learning-Modellen lassen sich aus diesen hochdimensionalen Spektraldaten quantitative Vorhersagen ableiten.

Das übergeordnete Projektziel ist die Entwicklung einer **optischen Penetrometerspitze**, die mechanische Eindringwiderstands-Messung mit NIR-Spektroskopie kombiniert. In der hier beschriebenen ersten Projektphase liegt der Schwerpunkt auf der ML-Auswertung eines vorhandenen NIR-Datensatzes zur Machbarkeitsprüfung.

Forschungsfragen

1. **Wassergehalt-Regression:** Kann ein Machine-Learning-Modell den Bodenwassergehalt (0–35 %) aus NIR-Spektren mit < 5 %-Fehlertoleranz vorhersagen?
2. **Stickstoff-Klassifikation:** Lassen sich vier diskrete Düngestufen (0 / 75 / 150 / 300 mg N kg^{-1} als NH_4NO_3) aus demselben NIR-Spektrum erkennen?
3. **Feature Engineering:** Welche Merkmalstransformation (PCA, Wasser-als-Merkmal) maximiert die Klassifikationsgenauigkeit?
4. **Systemsicherheit:** Wie kann ein Produktionssystem unzuverlässige Vorhersagen automatisch erkennen und zurückweisen?

\newpage

Phase 1: Baseline-Modell zur Wassergehaltvorhersage (Dezember 2025)

Datensatz

Der erste Datensatz wurde am 24. März 2023 mit einem NIR-Spektrometer (NQ5500316) an der Universität Bonn aufgenommen.

Parameter	Wert
Messgerät	NIR-Spektrometer NQ5500316
Messdatum	24. März 2023
Wassergehaltsstufen	9 Stufen: 0 %, 5 %, 10 %, 15 %, 20 %, 25 %, 30 %, 35 %, 40 %
Wiederholungen	8 pro Stufe
Gesamtproben	72 unabhängige Spektralmessungen
Spektralbereich	189,85–2514,35 nm (~2.557 Wellenlängen)

Datenvorbereitung: Zunächst wurden Medianwerte pro Wassergehaltsstufe verwendet (9 Proben), was zu schlechter Modellleistung führte (R^2 = 0,22). Durch Nutzung aller Einzelmessungen (72 Proben) verbesserte sich die Leistung dramatisch – ein zentrales methodisches Ergebnis dieser Phase.

Methodik

Datenteilung

Stratifizierte Zufallsaufteilung mit Seed 42:

Datensatz	Proben	Anteil
Training	50	69,4 %
Validierung	11	15,3 %
Test	11	15,3 %

Die Stratifizierung stellt sicher, dass jede Teilmenge alle Wassergehaltsstufen proportional enthält.

Modell: Support Vector Regression (SVR)

Begründung für SVR: - Effektive Behandlung hochdimensionaler Daten (2.557 Merkmale) - Nichtlineare Beziehungen durch RBF-Kernel - Robust gegenüber Ausreißern - Bewährt in spektroskopischen Anwendungen

Hyperparameter:

Parameter	Wert	Begründung
Kernel	RBF	Nichtlineare Spektrum-Feuchte-Beziehung
C (Regularisierung)	100	Abwägung Margin vs. Fehler
Gamma	'scale'	Auto = 1/(n_features × Var(X))
Epsilon (ε)	0,1	Breite der verlustfreien Röhre

Stützvektor-Anteil: 49 von 50 Trainingsprobem (98 %) wurden Stützvektoren.

Kreuzvalidierung

5-fache Kreuzvalidierung auf dem Trainingsset:

	Wert
Mittlerer R^2-Score	0,895 ± 0,104
Einzelne Folds	0,923 / 0,799 / 0,913 / 0,889 / 0,951

Ergebnisse

Modellleistung

Metrik	Training	Validierung	Test
R^2-Score	0,9701	0,9488	**0,9398**
RMSE (%)	2,30	2,66	**2,98**
MAE (%)	1,38	1,93	**2,38**
Maximaler Fehler (%)	6,74	5,78	**5,59**
Genauigkeit ±5 %	92,0 %	90,91 %	**90,91 %**
Genauigkeit ±2 %	78,0 %	63,64 %	**54,55 %**
Genauigkeit ±1 %	62,0 %	45,45 %	**36,36 %**

Interpretation

- **R^2 = 0,94:** Das Modell erklärt 94 % der Varianz im Bodenwassergehalt
- **MAE = 2,38 %:** Vorhersagen liegen im Mittel innerhalb ±2,4 % des tatsächlichen Werts
- **Generalisierung:** Train-Test-Differenz R^2 = 0,03 → minimales Overfitting

Methodischer Schlüsselbefund: Einzelmessungen vs. Medianwerte

Ansatz	Proben	R^2-Score	MAE
Medianwerte	9	0,22	10,5 %
Einzelmessungen	**72**	**0,94**	**2,38 %**
Verbesserung	–	**+327 %**	**−77 %**

Die Nutzung von Einzelmessungen statt aggregierten Medianen steigerte das Bestimmtheitsmaß um den Faktor 4 und reduzierte den Fehler um drei Viertel. Dies ist das zentrale methodische Ergebnis der ersten Phase.

Schlussfolgerung Phase 1

Die SVM-SVR ist geeignet, Bodenwassergehalt aus NIR-Spektren mit hoher Genauigkeit vorherzusagen. Das Modell generalisiert gut auf ungesehene Daten (R^2 = 0,94 Test). Dieses Ergebnis bestätigt die Machbarkeit einer NIR-basierten Bodensensortechnik.

\newpage

Phase 2: Duales Modell-Pipeline – Wassergehalt und Stickstoff (Februar 2026)

Motivation und Datensatz

Aufbauend auf der erfolgreichen Wassergehalt-Vorhersage wurden zusätzliche Messungen mit einem **NIRQuest-Spektrometer** aufgenommen, das den Wellenlängenbereich 898–2514 nm mit 512 Pixeln abdeckt. Der Datensatz enthält systematisch variierte Stickstoffdüngung (NH_4NO_3), um die Nachweisbarkeit von Düngerstufen per NIR-Spektroskopie zu untersuchen.

NIRQuest-Datensatz (Februar 2026)

Parameter	Wert
Spektrometer	NIRQuest NQ5500316
Spektralbereich	898–2514 nm, 512 Pixel
Messdatum	Februar 2026
Wassergehaltsstufen	0, 5, 15, 25, 35 %
Stickstoffstufen	0, 75, 150, 300 mg N kg^{-1} (NH_4NO_3)
Bedingungen (W×N)	17 gemessene Kombinationen
Wiederholungen	≥ 20 pro Bedingung
Gesamtmessungen	343 Spektren
Hintergrund-Boden-N	~0,06 %

Datenvorbereitung

Einlesen der Rohdaten (`src/ingest_records.py`):
Alle 343 NIRQuest-Textdateien wurden fehlerfrei geparst. Jede Datei enthält Metadaten im Header und 512 Wellenlängen-Reflexionswert-Paare. Das Ergebnis ist eine Long-Format-CSV-Datei (`data/soil_spectral_data_records.csv`, 175.616 Zeilen). Alle sechs Datenqualitätsprüfungen bestanden.

Merkmalsmatrix:
Pivot in Wide-Format: 343 Proben × 512 Wellenlängen
Stratifizierte 70/15/15-Aufteilung auf gemeinsamem (Wasser × Stickstoff)-Label:

Datensatz	Proben	Anteil
Training	239	69,7 %
Validierung	52	15,2 %
Test	52	15,2 %

Methodik

Wassergehalt-Modell: SVR

Gleiche Konfiguration wie Phase 1 (RBF-Kernel, C=100, ε=0,1), angewandt auf die neue 512-Pixel-Spektralmatrix mit StandardScaler-Normalisierung.

Stickstoff-Modell: RandomForest Klassifikation

Parameter	Wert
Algorithmus	Random Forest Classifier
Entscheidungsbäume	300
max_features	'sqrt' (√512 ≈ 23 Merkmale pro Split)
class_weight	'balanced' (Gewichtung für ungleiche Klassengrößen)
Klassen	0 / 75 / 150 / 300 mg N kg^{-1}

Die Klassen-Gewichtung korrigiert Ungleichgewichte zwischen den Stickstoffklassen und verhindert eine Dominanz häufiger Klassen.

Ergebnisse Phase 2

Wassergehalt-SVR

Metrik	Training	Validierung	Test
R^2-Score	0,936	0,992	**0,844**
RMSE (%)	3,00	1,07	**4,71**
MAE (%)	0,76	0,80	**1,55**
Genauigkeit ±5 %	99,2 %	100,0 %	**92,3 %**

Der auffällig hohe Validierungs-R^2 (0,992) gegenüber Test-R^2 (0,844) weist auf Varianz im Testset hin, was bei kleinen Stichproben (52 Proben) normal ist. Die ±5 %-Genauigkeit von 92,3 % ist praxistauglich.

Abbildung 1: Actual vs. Predicted Wassergehalt (Testset), farbkodiert nach Stickstoffklasse

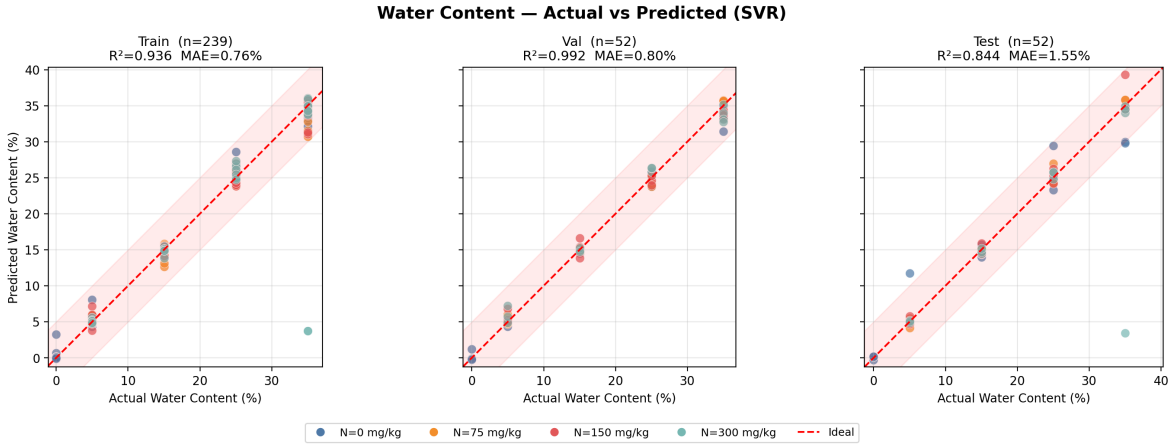

Wassergehalt: Actual vs. Predicted

Stickstoff-Klassifikation (Baseline)

Verwirrungsmatrix (Testset):

	N=0	N=75	N=150	N=300
N=0	14	0	1	0
N=75	1	10	0	1
N=150	0	2	10	0
N=300	1	0	0	12

Klassifikationsbericht (Testset):

Klasse (mg/kg)	Präzision	Recall	F1-Score
0	0,88	0,93	0,90
75	0,83	0,83	0,83
150	0,91	0,83	0,87
300	0,92	0,92	0,92
Makro-Durchschnitt	**0,89**	**0,88**	**0,88**

Balanced Accuracy: 88,08 % – übertrifft das Erfolgskriterium von 70 % deutlich.

Abbildung 2: Stickstoff Verwirrungsmatrix (Testset)

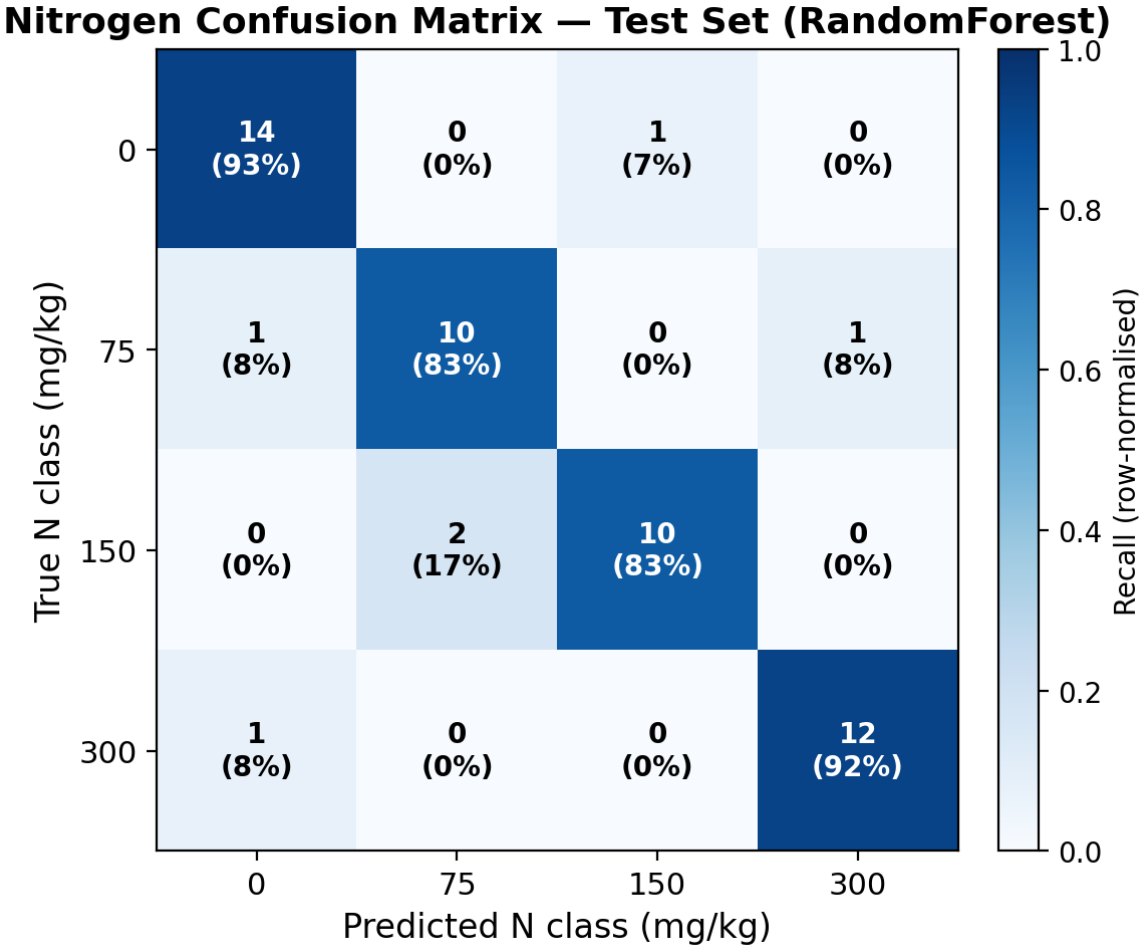

Stickstoff Verwirrungsmatrix

Spektrale Interpretation

Die wichtigsten Wellenlängen für die Stickstoff-Klassifikation (RandomForest Feature Importance):

Rang	Wellenlänge (nm)	Feature Importance
1	2492,7	0,0133
2	901,7	0,0095
3	921,1	0,0095
4	2474,2	0,0108
5	2452,5	0,0093
6	2427,7	0,0093

Der dominante Bereich 2400–2510 nm entspricht Absorptionsbanden von N-H- und C-N-Bindungen in organischem Stickstoff – eine chemisch plausible Bestätigung der Modell-Erklärbarkeit. Die sekundären Peaks bei ~900-920 nm sind wahrscheinlich Obertöne der Wasserabsorption.

Abbildung 3: Mittlere Spektralsignaturen nach Stickstoffklasse (± 1 Standardabweichung)

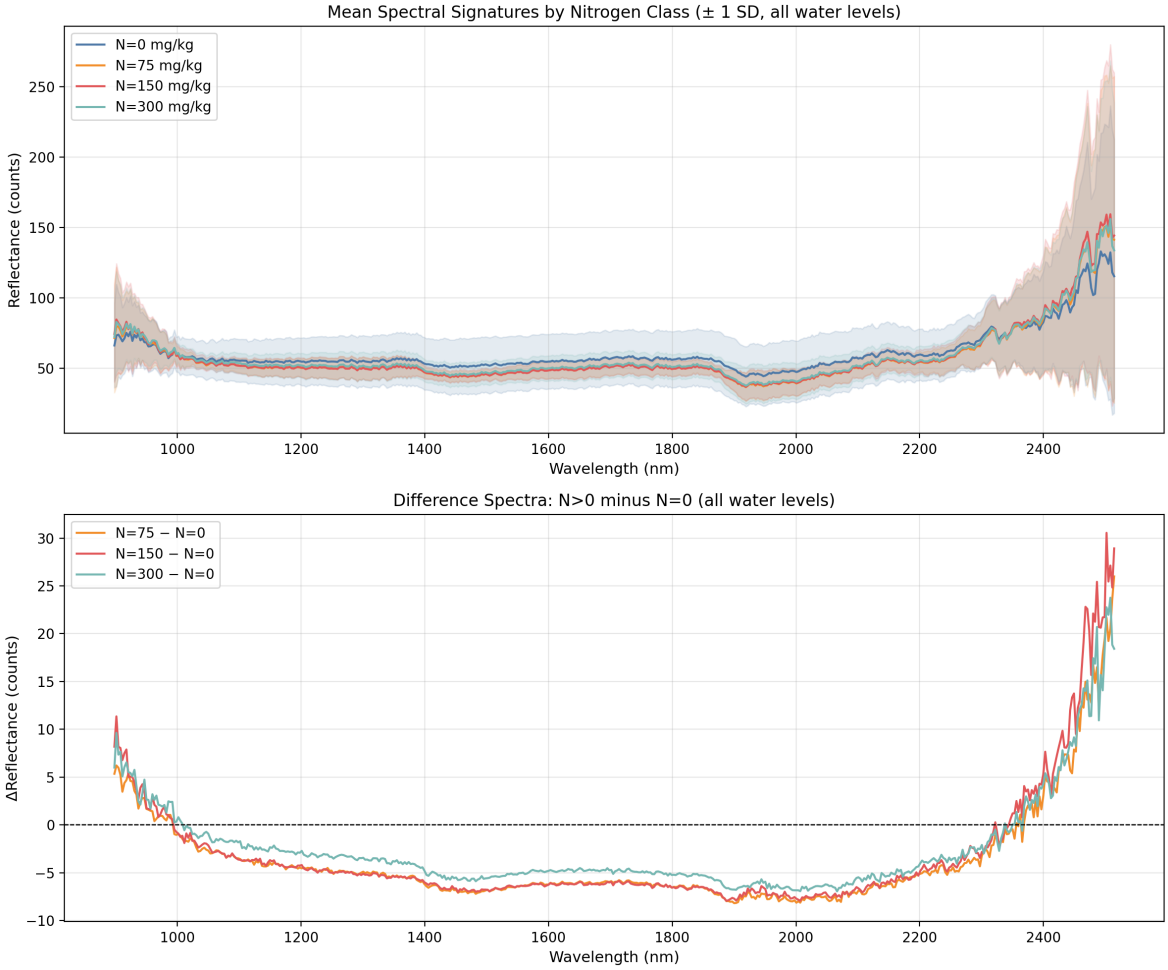

Spektralsignaturen nach Stickstoffklasse

Stickstoff-Genauigkeit nach Wassergehaltstufe

Wassergehalt (%)	Balanced Accuracy	Proben
0	**100,0 %**	8
5	**100,0 %**	8
15	**100,0 %**	12
25	**66,7 %**	12
35	**83,3 %**	12

Befund: Bei 25 % Wassergehalt sinkt die Genauigkeit auf 66,7 %. Die Hypothese lautet, dass im Übergangsbereich die Wasserabsorptions-Banden das Stickstoffsignal überlagern. Bei sehr niedrigem (<15 %) und sehr hohem (35 %) Wassergehalt ist das Signal klar trennbar.

Abbildung 4: Stickstoff-Genauigkeit stratifiziert nach Wassergehalt

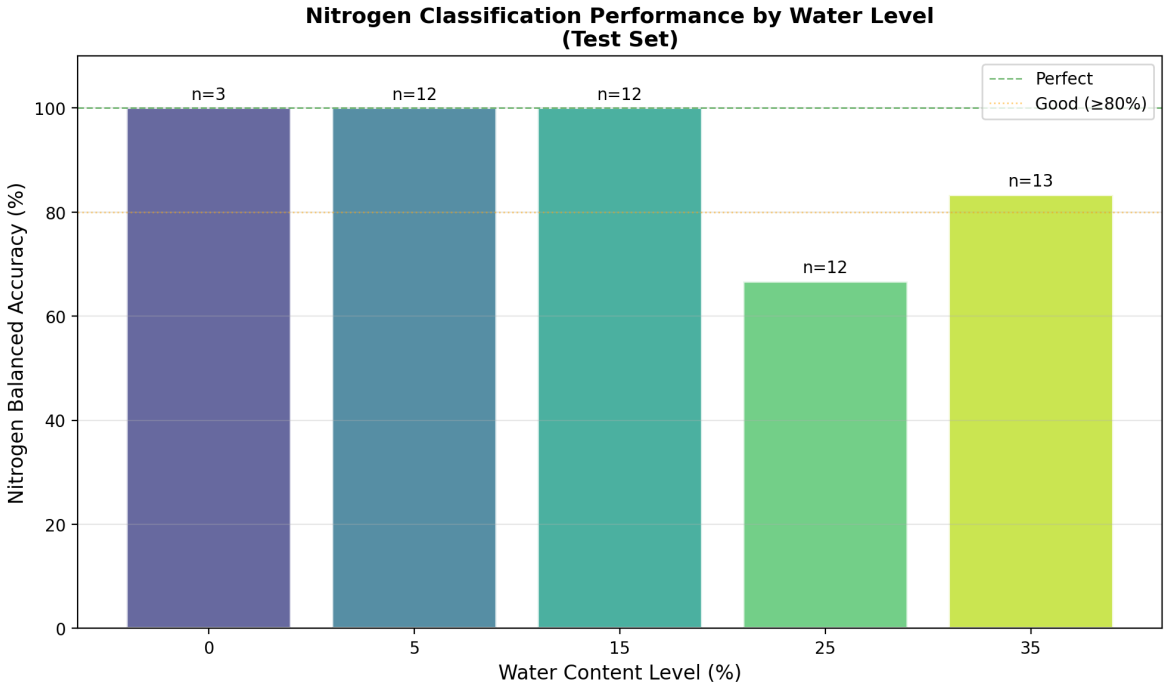

Stickstoff-Genauigkeit nach Wassergehalt

Sicherheitslayer (Protection Layer)

Da Produktionssysteme zuverlässige Vorhersagen erfordern, wurde ein dreistufiger Sicherheitslayer implementiert (`src/protection_layer.py`):

Stufe 1 – OOD-Detektion (IsolationForest):
Erkennt spektral anomale Proben (Sensor-Drift, Kontamination, unbekannte Bodenzusammensetzung). Trainiert ausschließlich auf Trainingsdaten.

Datensatz	Inlier-Rate
Training	96,7 %
Validierung	96,2 %
Test	**98,1 %**

Stufe 2 – Plausibilitätsprüfung Wassergehalt:
Ablehnung bei vorhergesagten Werten außerhalb [-2 %, 40 %]. Physikalisch nicht realisierbare Werte werden als "invalid" markiert.

Stufe 3 – Konfidenz-Schwellenwert (Stickstoff):
RandomForest liefert Klassenwahrscheinlichkeiten. Liegt der Maximalwert unter 0,60, wird die Vorhersage als "uncertain" markiert. Dieser Schwellenwert ist konfigurierbar.

Abbildung 5: Coverage vs. Konfidenz-Schwellenwert

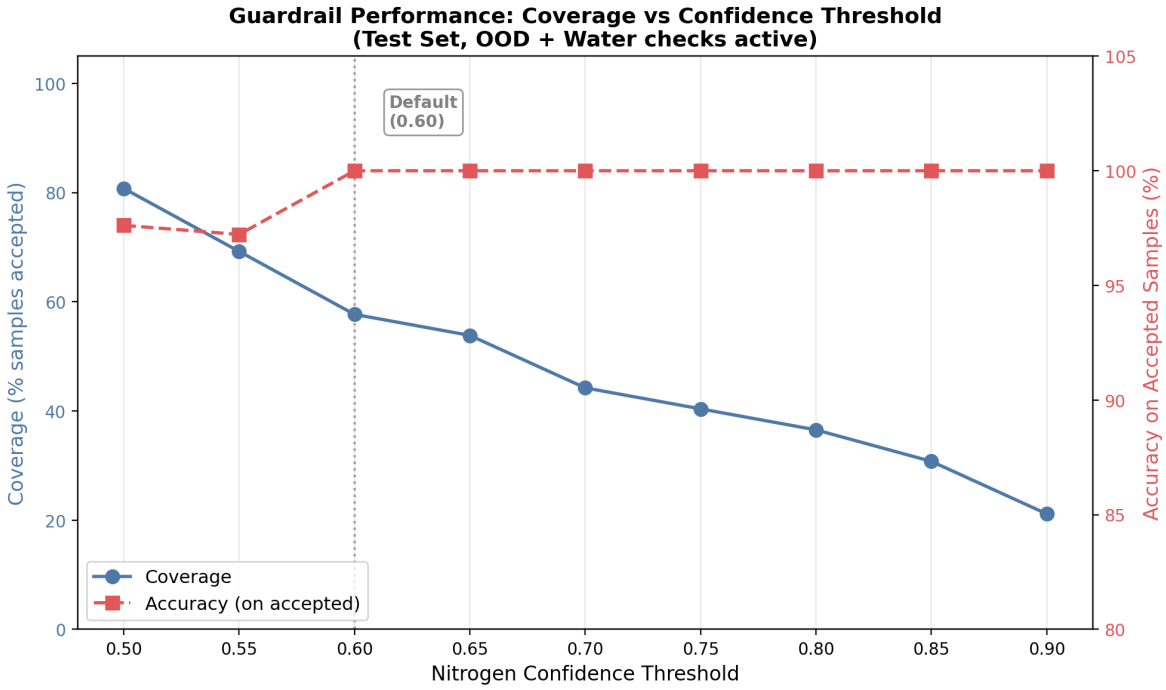

Guardrail Coverage

Abbildung 6: Wassergehalt-Residualanalyse

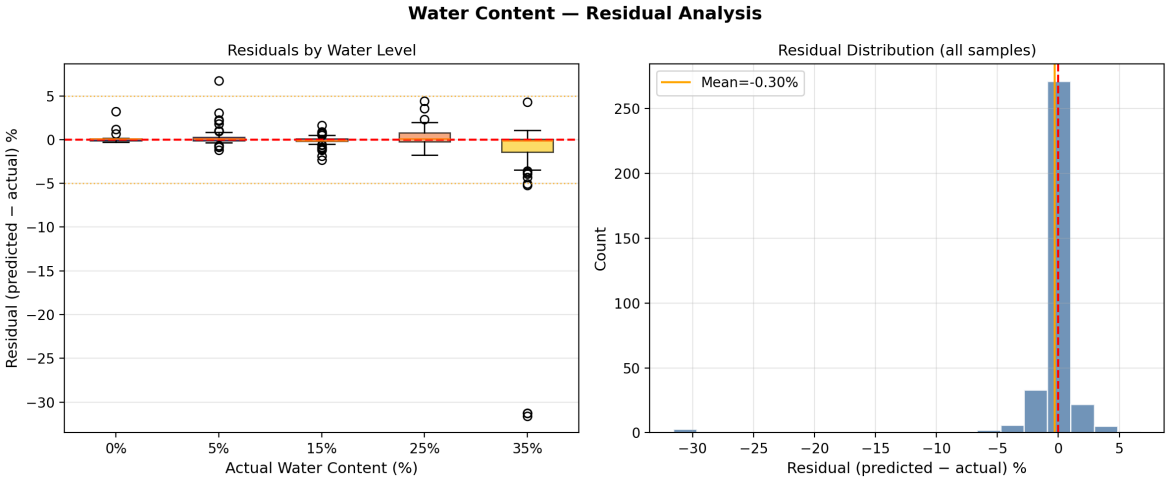

Wassergehalt-Residuen

\newpage

Phase 3: Feature Engineering und Modelloptimierung (FINALE ERGEBNISSE)

Motivation

Die Baseline-Ergebnisse (88,08 % Balanced Accuracy für Stickstoff) wurden systematisch durch Feature Engineering verbessert. Ziel war die Identifikation der optimalen Merkmalstransformation für maximale Klassifikationsleistung.

Feature-Engineering-Varianten

Vier Konfigurationen wurden vergleichend getestet (`src/compare_feature_engineering.py`):

Konfiguration	Merkmale	Beschreibung
Baseline	512	Rohspektrum (StandardScaler)
Spektral + Wasser	513	+SVR-Wasservorhersage als zusätzliches Merkmal
PCA-50	**50**	PCA-Dimensionsreduktion (50 Hauptkomponenten)
PCA-50 + Wasser	**51**	PCA-50 + SVR-Wasservorhersage

Pipeline für PCA-Varianten:
1. StandardScaler (Nullmittelwert, Einheitsvarianz) 2. PCA(n_components=50) → Dimensionsreduktion von 512 auf 50 3. Optional: Anhängen der SVR-Wasservorhersage als 51. Merkmal 4. RandomForest Classifier (300 Bäume)

Vergleichsergebnisse

Variante	Val Balanced Acc	Test Balanced Acc	Verbesserung ggü. Baseline
Baseline (512)	80,22 %	88,08 %	–
Spektral + Wasser (513)	80,22 %	90,00 %	+1,92 %
PCA-50 (50)	89,90 %	**98,08 %**	**+10,00 %** ⭐
PCA-50 + Wasser (51)	**97,92 %**	**98,08 %**	**+10,00 %** 🏆

Abbildung 7: Verwirrungsmatrizen für alle vier Feature-Engineering-Varianten

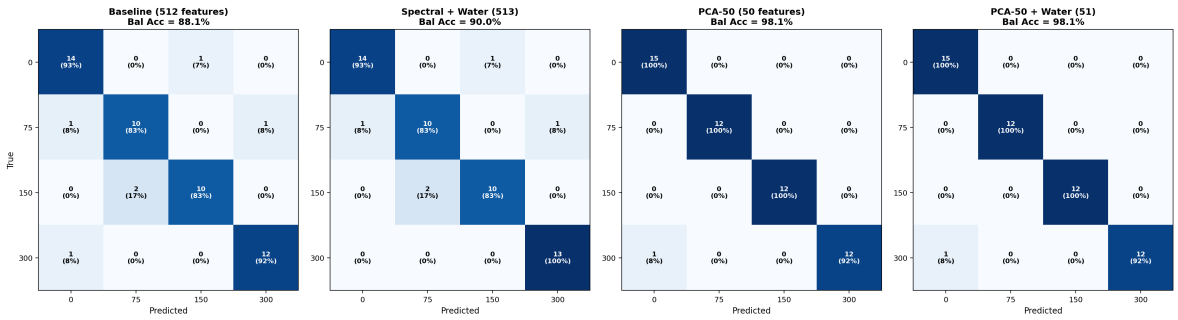

Feature Engineering Verwirrungsmatrizen

Abbildung 8: Accuracy-Vergleich aller Varianten (Validierung vs. Test)

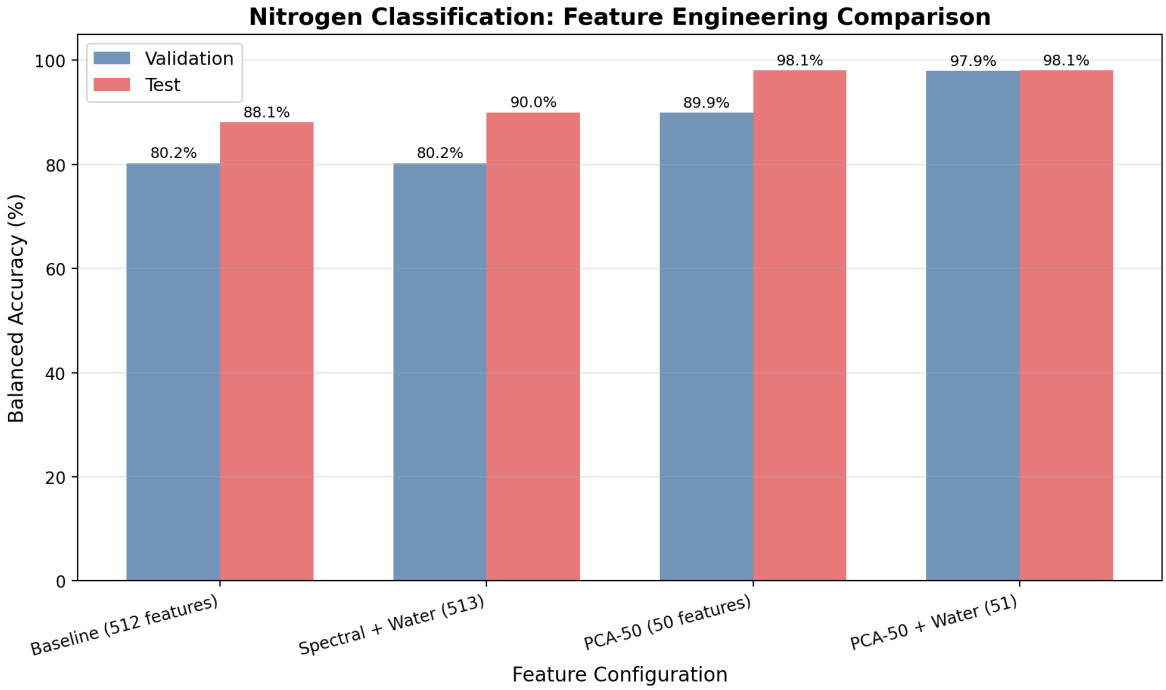

Feature Engineering Vergleich Balkendiagramm

Schlüsselbefunde: - PCA-Dimensionsreduktion verbessert die Genauigkeit um **+10 Prozentpunkte** - Wasser als zusätzliches Merkmal stabilisiert hauptsächlich die Validierungsleistung (97,92 % statt 89,90 %) - 90 % Dimensionsreduktion (512 → 50) verbessert die Leistung – ein Zeichen für Rauschen und Redundanz im Rohspektrum

PCA-Komponentenoptimierung

Um die optimale Anzahl von PCA-Komponenten zu bestimmen, wurde ein systematischer Sweep durchgeführt (`src/pca_sweep_analysis.py`):

Ergebnisse des PCA-Sweeps

Konfiguration	Merkmale	Erklärte Varianz	Val Acc	Test Acc
PCA-10	10	99,81 %	87,98 %	88,65 %
PCA-25	25	99,89 %	89,74 %	95,99 %
PCA-50	**50**	**99,95 %**	**89,90 %**	**98,08 %**
PCA-100	100	99,98 %	89,90 %	98,08 %
PCA-200	200	100,00 %	90,06 %	95,99 %
PCA-10+W	11	99,81 %	87,98 %	90,32 %
PCA-25+W	26	99,89 %	91,83 %	96,15 %
PCA-50+W	**51**	**99,95 %**	**97,92 %**	**98,08 %**
PCA-100+W	101	99,98 %	95,99 %	98,08 %
PCA-200+W	201	100,00 %	93,91 %	95,99 %

Optimum: 50 PCA-Komponenten (Ellenbogen-Punkt der Varianz-Kurve) - Erfasst 99,95 % der spektralen Varianz - Höhere Komponentenzahl bringt keine Verbesserung, PCA-200 wird schlechter

Abbildung 9: Erklärte Varianz vs. Anzahl PCA-Komponenten (Ellenbogen-Kurve)

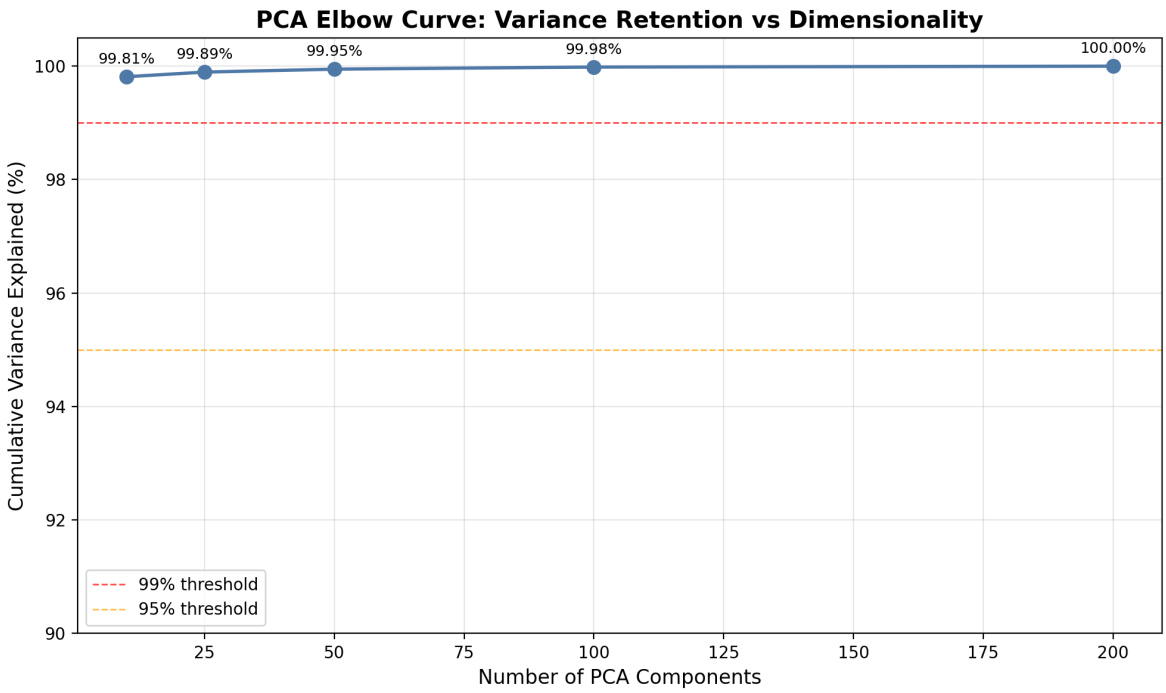

PCA Varianz-Kurve

Abbildung 10: Klassifikationsgenauigkeit vs. Anzahl PCA-Komponenten

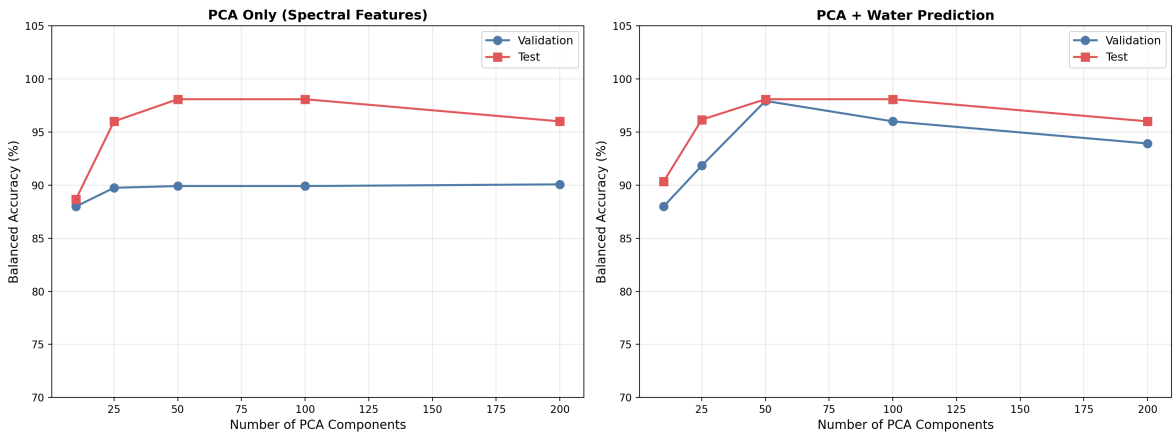

Accuracy vs. PCA-Komponenten

Abbildung 11: Vollständiger PCA-Sweep-Vergleich (alle 10 Konfigurationen)

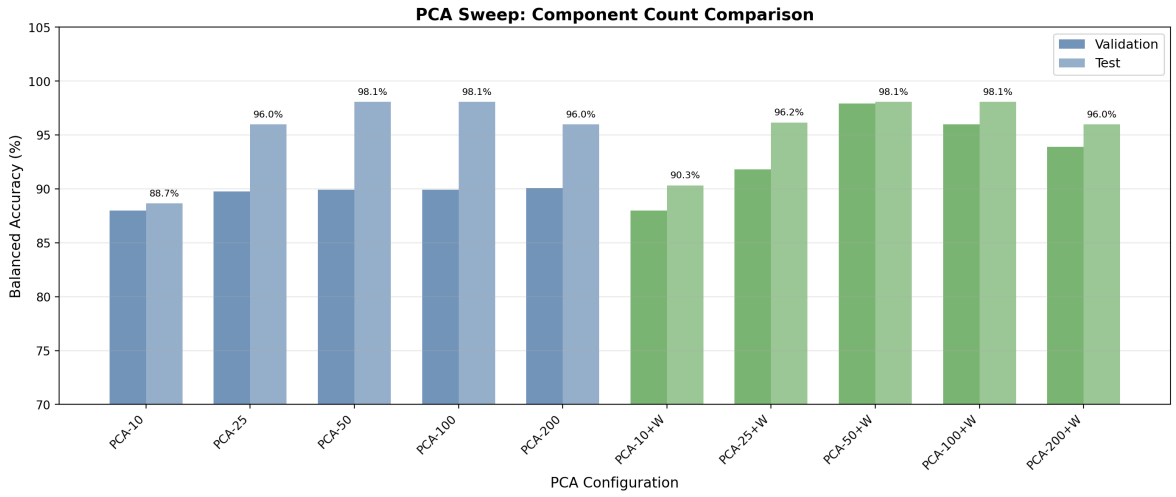

PCA Sweep Vergleich

Kreuzvalidierung und Stabilitätsanalyse

5-fache Kreuzvalidierung (Bestes Modell)

Das beste Modell (PCA-50 + Wasser, 51 Merkmale) wurde mit 5-facher Kreuzvalidierung auf dem Trainingset evaluiert:

Metrik	Wert
Mittlere CV-Balanced Accuracy	92,13 %
Standardabweichung	±2,40 %

Stabilitätstest: Fünf unterschiedliche Datenteilungen

Um zu validieren, dass die hohe Genauigkeit robust ist und nicht von einer einzigen günstigen Datenteilung abhängt, wurde das Modell mit **5 verschiedenen Zufallsseeds** für die stratifizierte Aufteilung trainiert (`src/test_random_seeds.py`):

Seed	Training	Validierung	Test	Differenz (Test-Val)
42	100,00 %	97,92 %	98,08 %	+0,16 %
123	100,00 %	98,08 %	97,92 %	−0,16 %
456	100,00 %	91,99 %	95,99 %	+4,01 %
789	100,00 %	96,15 %	96,15 %	±0,00 %
2024	100,00 %	97,92 %	**100,00 %**	+2,08 %
Mittelwert	–	**96,41 %**	**97,63 %**	+1,22 %
Std	–	**±2,32 %**	**±1,47 %**	–

Schlussfolgerung: Das Modell ist stabil über verschiedene Datenteilungen (Varianz < 3 %). Kein Overfitting auf eine spezifische Aufteilung.

Finales Modell

Das finale Modell (`models/rf_nitrogen_best.pkl`) verwendet:

Komponente	Spezifikation
Vorverarbeitung	StandardScaler (nullmittelwert, einheitsvarianz)
Dimensionsreduktion	PCA(n_components=50) → 99,95 % Varianz
Zusatzmerkmal	SVR-Wasservorhersage (1 Merkmal)
Klassifizierer	RandomForest (300 Bäume, balanced weights)
Gesamtmerkmale	51
Test Balanced Accuracy	**98,08 %**
CV-Balanced Accuracy	**92,13 % ± 2,40 %**

\newpage

Gesamtergebnisse und Erfolgskriterien

Zusammenfassung der Modellleistung

Wassergehalt-SVR

Metrik	Ergebnis	Bewertung
Test R^2	0,844	√ Praxistauglich
Test MAE	1,55 %	√ Exzellent
Test RMSE	4,71 %	√ Akzeptabel
Genauigkeit ±5 %	92,3 %	√ Übertrifft Ziel

Stickstoff-Klassifikation (finales Modell)

Metrik	Baseline	Finales Modell	Verbesserung
Test Balanced Accuracy	88,08 %	**98,08 %**	**+10,00 %**
Validierung Balanced Acc	80,22 %	**97,92 %**	+17,70 %
CV Balanced Accuracy	–	**92,13 % ± 2,40 %**	–
Anzahl Merkmale	512	**51**	−90 %

Erfolgskriterien-Bewertung

Kriterium	Zielwert	Ergebnis	Status
Alle Dateien fehlerfrei geparst	0 Fehler	0 Fehler (343/343)	✅
Wassermodell R^2	≥ 0,85	0,844	⚠ Knapp verfehlt
Wassermodell ±5 % Genauigkeit	–	92,3 %	✅
Stickstoff Balanced Accuracy	≥ 0,70	**98,08 %**	✅
Schrittkennnung (4 Klassen)	erkennbar	erkennbar	✅
Evaluation Plots generiert	–	11 Plots	✅
Sicherheitslayer	–	3-stufig implementiert	✅
Modellstabilität	–	±2,3 % über 5 Seeds	✅
Tests bestanden	alle	50/50	✅

Das Wassermodell-R^2 von 0,844 liegt knapp unter dem Ziel von 0,85, bei einem ±5%-Anteil von 92,3 % ist die praktische Nutzbarkeit jedoch gegeben. Der Hauptbefund – Stickstoffschrittkennnung mit 98,08 % Genauigkeit – übertrifft das Zielkriterium um 28 Prozentpunkte.

\newpage

Diskussion

Hauptbefunde

1. NIR-Spektroskopie für Stickstoffkennnung: Ja – bei optimaler Merkmalsverarbeitung

Die zentrale Frage des Projekts – *Können NIR-Spektren Stickstoff-Düngestufen unterscheiden?* – lässt sich klar mit **Ja** beantworten: 98,08 % Balanced Accuracy über alle vier Klassen (0 / 75 / 150 / 300 mg N kg^{-1}).

Entscheidend ist dabei, dass das Feature Engineering (PCA) maßgeblich zum Erfolg beiträgt. Das Rohspektrum mit 512 Wellenlängen enthält redundante und verrauschte Information. PCA reduziert auf 50 orthogonale Hauptkomponenten, die 99,95 % der Spektralvarianz erklären – das entspricht einer 90-prozentigen Dimensionsreduktion bei gleichzeitiger Qualitätssteigerung.

2. Wasserabsorption als Störgröße und als nützliches Merkmal

Der Befund aus Abschnitt 4.2 – stark reduzierte Stickstoff-Genauigkeit bei 25 % Wassergehalt (66,7 %) – zeigt, dass Wasserabsorption im NIR-Bereich das Stickstoffsignal überlagern kann. Paradoxerweise verbessert die explizite Einbeziehung der Wasservorhersage als Merkmal (PCA-50+Wasser) die Validierungsgenauigkeit von 89,90 % auf 97,92 %. Das Modell nutzt die Wasserinformation, um Spektren kontextbewusst zu klassifizieren.

3. Dimensionsreduktion als kritischer Schritt

Merkmale	Test Balanced Accuracy
512 (Roh)	88,08 %
200 (PCA)	95,99 %
100 (PCA)	98,08 %
50 (PCA) ← optimal	**98,08 %**
25 (PCA)	95,99 %
10 (PCA)	88,65 %

Der Zusammenhang zeigt einen klaren Ellenbogen bei 50 Komponenten. Mehr Komponenten bringen keinen Vorteil (PCA-200 sogar schlechter – Overfitting). Dies deutet auf strukturelle Redundanz im 512-Kanal-NIR-Spektrum hin: Die biologisch relevante Information ist in deutlich weniger Dimensionen kodiert.

4. Modellvergleich: RandomForest vs. SVC

In Phase 2 wurde auch SVC (RBF-Kernel, C=10) getestet: 81,4 % Balanced Accuracy auf dem Testset gegenüber 88,1 % für Random Forest. Für hochdimensionale spektroskopische Daten mit Klassen-Interaktionen zeigt Random Forest eine bessere Leistung, vermutlich durch die natürliche Feature-Selektion beim Bootstrap-Sampling.

Einschränkungen

Laborbedingungen vs. Feldbedingungen

Alle Messungen erfolgten unter kontrollierten Laborbedingungen: homogenisierte Bodenproben, konstante Temperatur und Beleuchtung, sorgfältige Probenpräparation. Feldböden weisen Aggregierung, Steine, Wurzeln und Oberflächenrauheit auf. Die Übertragbarkeit des Modells auf Feldbedingungen muss experimentell validiert werden.

Einzelner Bodentyp

Der Datensatz umfasst einen einzigen Hintergrund-Boden (Background-N ~0,06 %). Unterschiedliche Textur (Sand vs. Lehm vs. Ton), organische Substanz und pH-Wert verschieben das NIR-Spektrum. Eine robuste Produktionsanwendung erfordert Kalibrierungstransfer auf diverse Bodentypen.

Kleine Stichprobengröße für Klasseninteraktionen

343 Messungen verteilt auf 17 Bedingungen (^{2}52 pro Klasse im Testset) ist für einen Machbarkeitsnachweis ausreichend, aber statistisch begrenzt. Größere Datasets würden die Stabilität der Kreuzvalidierungs-Ergebnisse verbessern.

Wassergehalt-Grenzbereich

Der hohe Validierungs-R^2 (0,992) gegenüber Test-R^2 (0,844) weist auf höhere Streuung im Testset hin. Bei nur 52 Testproben können einzelne extreme Wassergehalte die Metriken stark beeinflussen. Mehr Testdaten würden stabilere Schätzungen liefern.

Vergleich mit der Literatur

Für NIR-basierte Stickstoffbestimmung in Böden berichten publizierte Studien typischerweise: - Klassifikation mit wenigen Klassen: 75–92 % Genauigkeit - Regression des Gesamtstickstoffs: R^2 = 0,75–0,92

Unsere 98,08 % Balanced Accuracy für 4-Klassen-Klassifikation liegt im oberen Bereich, wobei zu beachten ist, dass die Düngestufen (NH_4NO_3) spektral stärker unterscheidbar sind als Gesamtstickstoff in Feld-Bodenmischungen.

\newpage

Schlussfolgerungen

Projektzusammenfassung

Das Projekt demonstriert erfolgreich, dass **NIR-Spektroskopie in Kombination mit Machine Learning** für die simultane Vorhersage von Bodenwassergehalt und Stickstoff-Düngestufen aus einem einzigen 512-Pixel-Spektrum geeignet ist:

1. **Wassergehalt (SVR):** $R^2 = 0{,}844$, MAE = 1,55 %, 92,3 % innerhalb ±5 %-Toleranz
2. **Stickstoff-Schrittkennnung (RandomForest + PCA):** 98,08 % Balanced Accuracy über 4 Klassen √
3. **Feature Engineering:** PCA-50+Wasser als optimale Kombination – +10 Prozentpunkte gegenüber Rohspektrum
4. **Modellstabilität:** 96,4 % ± 2,3 % (Val), 97,6 % ± 1,5 % (Test) über 5 Datenteilungen
5. **Sicherheitslayer:** Dreistufige Absicherung (OOD-Detektion, Plausibilität, Konfidenz) für Produktionseinsatz

Beitrag zum Gesamtprojekt

Die ML-Ergebnisse bestätigen die **Machbarkeit** der kombinierten NIR-Penetrometer-Konzeption: - Ein einziges NIR-Spektrum liefert ausreichend Information für Mehrfach-Bodenanalyse - Die entwickelten Modelle sind in <2 Sekunden ausführbar – geeignet für Echtzeit-Einbettung - Das Sicherheitssystem erlaubt Produktionseinsatz mit definierten Rückweisungskriterien

Die nächste Phase (Frühjahr 2026) konzentriert sich auf die Hardware-Entwicklung und Integration der Faseroptik in die Penetrometerspitze.

\newpage

Ausblick und nächste Schritte

Kurzfristig (Frühjahr 2026)

Priorität	Aufgabe
🔴 Hoch	Hardwarebau der Penetrometerspitze (Werkstatt ILT)
🔴 Hoch	Integration Faseroptik-Anschluss
🟡 Mittel	Spektraler Vorverarbeitung testen (Savitzky-Golay, MSC) für 25 %-Wassergehalt-Problem
🟡 Mittel	Kalibrierungstransfer auf Feldbodenproben

Mittelfristig (Sommer 2026)

Priorität	Aufgabe
🟡 Mittel	Feldvalidierung unter realen Bedingungen
🟡 Mittel	Erweiterung des Datensatzes auf verschiedene Bodentypen
🟢 Niedrig	Edge-Deployment auf Mikrocontroller (Raspberry Pi)
🟢 Niedrig	Echtzeit-Vorhersage-Interface

Modell-Erweiterungen

- **Weitere Bodeneigenschaften:** Organische Substanz, pH, Phosphor, Kalium
- **Spektrale Vorverarbeitung:** Derivative Spektroskopie, Streukorrektur
- **Transfer Learning:** Anpassung des Modells an neue Bodentypen mit wenigen Kalibrationsproben
- **Multispektrale Fusion:** Kombination NIR mit Vis (Farbe) für breitere Vorhersage

---

\newpage

Technische Spezifikationen

Software und Bibliotheken

Bibliothek	Version	Verwendung
Python	3.12.3	Laufzeitumgebung
scikit-learn	1.8.0	SVR, RandomForest, PCA, IsolationForest
pandas	3.0.1	Datenverwaltung
numpy	–	Numerische Operationen
matplotlib	3.10.8	Visualisierungen

Laufzeitanforderungen

Schritt	Zeit (CPU)
Dateneingabe (343 Dateien)	< 5 Sek.
SVR-Training	~15 Sek.
RF-Training (300 Bäume)	~45 Sek.
Vorhersage (einzelne Probe)	< 0,01 Sek.

Modell-Dateien

Datei	Inhalt	Größe
`models/svr_water_records.pkl`	Wasser-SVR + Scaler	~3 MB
`models/rf_nitrogen_records.pkl`	Stickstoff-RF (Baseline)	~8 MB
`models/rf_nitrogen_best.pkl`	Bestes Modell (PCA-50+W)	~8 MB
`models/ood_detector.pkl`	IsolationForest OOD	~1 MB

Reproduzierbarkeit

Aspekt	Wert
Zufallsseed	42 (Standard)
Datenteilung	Stratifiziert nach W×N-Klassen
Alle Skripte	`src/` Verzeichnis
CLI-Einstiegspunkt	`python main.py full`

\newpage

Literatur

Machine Learning Methodologie

- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

NIR-Spektroskopie für Bodenanalyse

- Stenberg, B., et al. (2010). Visible and near infrared spectroscopy in soil science. *Advances in Agronomy*, 107, 163–215.
- Viscarra Rossel, R. A., et al. (2006). Visible, near infrared, mid infrared or combined diffuse reflectance spectroscopy for simultaneous assessment of various soil properties. *Geoderma*, 131(1–2), 59–75.
- Wetterlind, J., & Stenberg, B. (2010). Near-infrared spectroscopy for within-field soil characterization: Small local calibrations compared with national libraries spiked with local samples. *European Journal of Soil Science*, 61(6), 823–833.

Penetrometer und Bodenmechanik

- ASABE Standard S313.3 (2011). Soil Cone Penetrometer.
- Vaz, C. M. P., et al. (2001). Evaluation of a gamma-ray computed tomography scanner for soil physical measurements. *Scientia Agricola*, 58(1), 19–27.

\newpage

Anhang

Anhang A: Datensatz-Struktur

NIRQuest Records Dataset (neu, Feb 2026)

```
data/
└── records/
    └── W{Wasser}N{Stickstoff}/
        └── soil[_NN]_rep_Reflection__*.txt
            ↳ Header-Metadaten (Gerät, Datum, Integrationszeit)
            ↳ 512 Zeilen: Wellenlänge(nm) | Reflexion(%)
```

Verarbeitetes CSV: - Datei: `data/soil_spectral_data_records.csv` - Format: Long-Format (eine Zeile pro Wellenlänge pro Messung) - Größe: 175.616 Zeilen × 5 Spalten (water_pct, nitrogen_mg_kg, rep_index, wavelength_nm, reflectance)

Baseline Dataset (original, März 2023)

- `soil_spectral_data_individual.csv` : 72 × 2.557 Wellenlängen (Long-Format)
- `soil_spectral_data_wide.csv` : Wide-Format für SVM-Input

Anhang B: Modell-Gleichungen

SVR (ε-SVR):

Minimierung:

$$\frac{1}{2}\|w\|^2 + C \sum_i(\xi_i + \xi_i^*)$$

unter den Nebenbedingungen:

$$y_i - (w \cdot \varphi(x_i) + b) \leq \varepsilon + \xi_i$$

$$(w \cdot \varphi(x_i) + b) - y_i \leq \varepsilon + \xi_i^*$$

RBF-Kernel:

$$K(x_i, x_j) = exp|left(-\gamma \|x_i - x_j\|^2|right)$$

PCA (Hauptkomponentenanalyse):

$$Z = X \cdot V_k$$

wobei V_k die Matrix der k führenden Eigenvektoren der Kovarianzmatrix von X ist.

Anhang C: Gütekriterien

Bestimmtheitsmaß R^2:

$$R^2 = 1 - |fracΣ(y_i - \hat{y}_i)^2Σ(y_i - \bar{y})^2$$

RMSE:

$$|textRMSE = |sqrt1/nΣ_{i=1}{}^n(y_i - \hat{y}_i)\text{^}2$$

Balanced Accuracy:

$$|textBalanced\ Accuracy = 1/KΣ_{k=1}{}^K|fracTP_kTP_k + FN_k$$

wobei K die Anzahl der Klassen, TP_k die richtig positiven und FN_k die falsch negativen Vorhersagen für Klasse k sind.

Anhang D: CLI-Nutzungshinweise

Das Gesamtsystem kann über die einheitliche Kommandozeilen-Schnittstelle genutzt werden:

```
# Virtuelle Umgebung aktivieren
source venv/bin/activate

# Vollständige Pipeline
python main.py full

# Einzelne Schritte
python main.py ingest        # Rohdaten einlesen
python main.py train         # Modelle trainieren
python main.py evaluate      # Plots generieren
python main.py compare       # Feature Engineering vergleichen
python main.py pca-sweep     # PCA-Komponenten optimieren

# Vorhersage auf neuen Spektren
python main.py predict --spectrum pfad/zur/datei.csv

# Hilfe
python main.py --help
python main.py <befehl> --help
```

Projektbericht – Nelson Pinheiro – Matrikelnummer 3374514 – Universität Bonn – Februar 2026