\newpage

Kurzfassung

Bodenverdichtung, Wasserhaushalt und Naehrstoffverfuegbarkeit sind zentrale Steuergroessen fuer Pflanzenwachstum und Ertrag. Dieses Projekt untersucht in einer ersten Projektphase die **Machine-Learning-Auswertung von NIR-Spektraldaten** zur simultanen Vorhersage von Bodenwassergehalt und Stickstoff-Duengestufen - als Machbarkeitsnachweis fuer die geplante optische Penetrometerspitze.

Ergebnisse im Ueberblick:

Phase	Modell	Wichtigste Kennzahl
1 - Baseline Wasser (Dez 2025)	SVR (2.557 Wellenlaengen)	R2 = 0,94 - MAE = 2,38 % - +/-5 % = 91 %
2 - Duales Modell (Feb 2026)	SVR + RandomForest (512 Pixel)	R2(W) = 0,84 - Balanced Acc(N) = 88,1 %
3 - Feature Engineering (Feb 2026)	PCA-50 + Wasservorhersage	**Balanced Acc(N) = 98,08 %** (+10 PP)

Das finale Modell (PCA-50 + SVR-Wassermerkmal, RandomForest, 300 Baeume) uebertrifft das urspruengliche Zielkriterium von 70 % Balanced Accuracy um 28 Prozentpunkte und ist stabil ueber 5 verschiedene Datenteilungen (97,6 % +/- 1,5 %).

\newpage

Einleitung

Hintergrund und Motivation

Praezisionslandwirtschaft erfordert raeumlich und zeitlich hochaufgeloeste Informationen ueber den Bodenstatus. Bodenwassergehalt und Naehrstoffverfuegbarkeit - insbesondere Stickstoff - sind zentrale Parameter fuer Bewaesserungs- und Dueungungsmanagement. Traditionelle Analysemethoden (Gravimetrie fuer Wasser, Nasschemie fuer Stickstoff) sind zeitaufwendig, destruktiv und zu kostspielig fuer flaechendeckende Anwendungen.

Die nahinfrarote Spektroskopie (NIR, 700-2500 nm) bietet eine schnelle, nicht-destruktive Alternative: Ein Lichtstrahl tritt ins Bodenmaterial ein, wird reflektiert, und das Reflexionsspektrum enthaelt Information ueber chemische Bindungen (O-H, N-H, C-H), die direkt mit Wassergehalt und organischer Substanz korrelieren. In Verbindung mit Machine-Learning-Modellen lassen sich aus diesen hochdimensionalen Spektraldaten quantitative Vorhersagen ableiten.

Das uebergeordnete Projektziel ist die Entwicklung einer **optischen Penetrometerspitze** (normgerecht nach ASABE S313.3), die mechanische Eindringwiderstandsmessung mit NIR-Spektroskopie kombiniert. In der hier beschriebenen ersten Projektphase liegt der Schwerpunkt auf der ML-Auswertung vorhandener NIR-Datensaetze zur Machbarkeitspruefung.

Forschungsfragen

1. Kann ein SVR-Modell den Bodenwassergehalt (0-40 %) aus NIR-Spektren mit < 5 %-Fehlertoleranz vorhersagen?
2. Lassen sich vier diskrete Stickstoff-Duengestufen (0 / 75 / 150 / 300 mg N/kg) aus einem NIR-Spektrum erkennen?
3. Welche Merkmalstransformation (PCA, Wasser-als-Merkmal) maximiert die Klassifikationsgenauigkeit?

\newpage

Phase 1: Baseline-Modell zur Wassergehaltvorhersage (Dezember 2025)

Datensatz

Messungen am 24. Maerz 2023 mit einem NIR-Spektrometer (NQ5500316) an der Universitaet Bonn.

Parameter	Wert
Messgeraet	NIR-Spektrometer NQ5500316
Wassergehaltsstufen	9 Stufen: 0-40 %, je 8 Wiederholungen
Gesamtproben	72 unabhaengige Spektralmessungen
Spektralbereich	189,85-2514,35 nm (~2.557 Wellenlaengen)
Spektralbereiche	UV (189-400 nm), Sichtbar (400-700 nm), NIR (700-2514 nm)

Methodik

Datenvorbereitung und -teilung

Stratifizierte Zufallsaufteilung (Seed 42): Training 50 / Validierung 11 / Test 11 Proben (69 / 15 / 15 %). Alle Messungen skaliert mit StandardScaler (Nullmittelwert, Einheitsvarianz).

Methodischer Schluesselbefund:

Ansatz	Proben	R2-Score	MAE
Medianwerte	9	0,22	10,5 %
Einzelmessungen	**72**	**0,94**	**2,38 %**
Verbesserung	-	**+327 %**	**-77 %**

Die Nutzung aller Einzelmessungen statt aggregierter Medianwerte steigerte das Bestimmtheitsmass um Faktor 4 und ist das zentrale methodische Ergebnis dieser Phase.

Modell: Support Vector Regression (SVR)

SVR mit RBF-Kernel eignet sich fuer hochdimensionale Spektraldaten mit nichtlinearen Abhaengigkeiten.

Hyperparameter	Wert	Begruendung
Kernel	RBF	Nichtlineare Spektrum-Feuchte-Beziehung
C	100	Abwaegung Margin vs. Fehler
Gamma	'scale'	1/(n_features x Var(X)) automatisch
Epsilon	0,1	Breite der verlustfreien Roehre

5-fache Kreuzvalidierung auf dem Trainingsset: mittlerer R2 = 0,895 +/- 0,104 (Folds: 0,923 / 0,799 / 0,913 / 0,889 / 0,951). Stuetzvektoren: 49/50 (98 %).

Ergebnisse Phase 1

Metrik	Training	Validierung	Test
R2-Score	0,9701	0,9488	**0,9398**
RMSE (%)	2,30	2,66	**2,98**
MAE (%)	1,38	1,93	**2,38**
Max. Fehler (%)	6,74	5,78	**5,59**
Genauigkeit +/-5 %	92,0 %	90,91 %	**90,91 %**
Genauigkeit +/-2 %	78,0 %	63,64 %	**54,55 %**
Genauigkeit +/-1 %	62,0 %	45,45 %	**36,36 %**

R2 = 0,94: Das Modell erklaert 94 % der Varianz im Bodenwassergehalt. Die Train-Test-Differenz von 0,03 zeigt minimales Overfitting. 90,91 % der Testvorhersagen liegen innerhalb der praxistauglichen +/-5 %-Toleranz.

Physikalische Interpretation: NIR detektiert Wasser ueber O-H-Streckschwingungen (~1.400-1.450 nm, ~1.900-1.950 nm) und Kombinationsbanden (~970 nm). Das Modell erfasst diese Signaturen ohne manuelle Merkmalsselektion - durch die implizite RBF-Transformation des SVR.

Leistungsvergleich mit der Literatur: Typische NIR-basierte Wassergehalt-Vorhersagen berichten R2 = 0,75-0,95 und MAE = 2-5 % (Stenberg et al. 2010; Viscarra Rossel et al. 2006). Unser Ergebnis (R2 = 0,94, MAE = 2,38 %) liegt im oberen Bereich publizierter Studien.

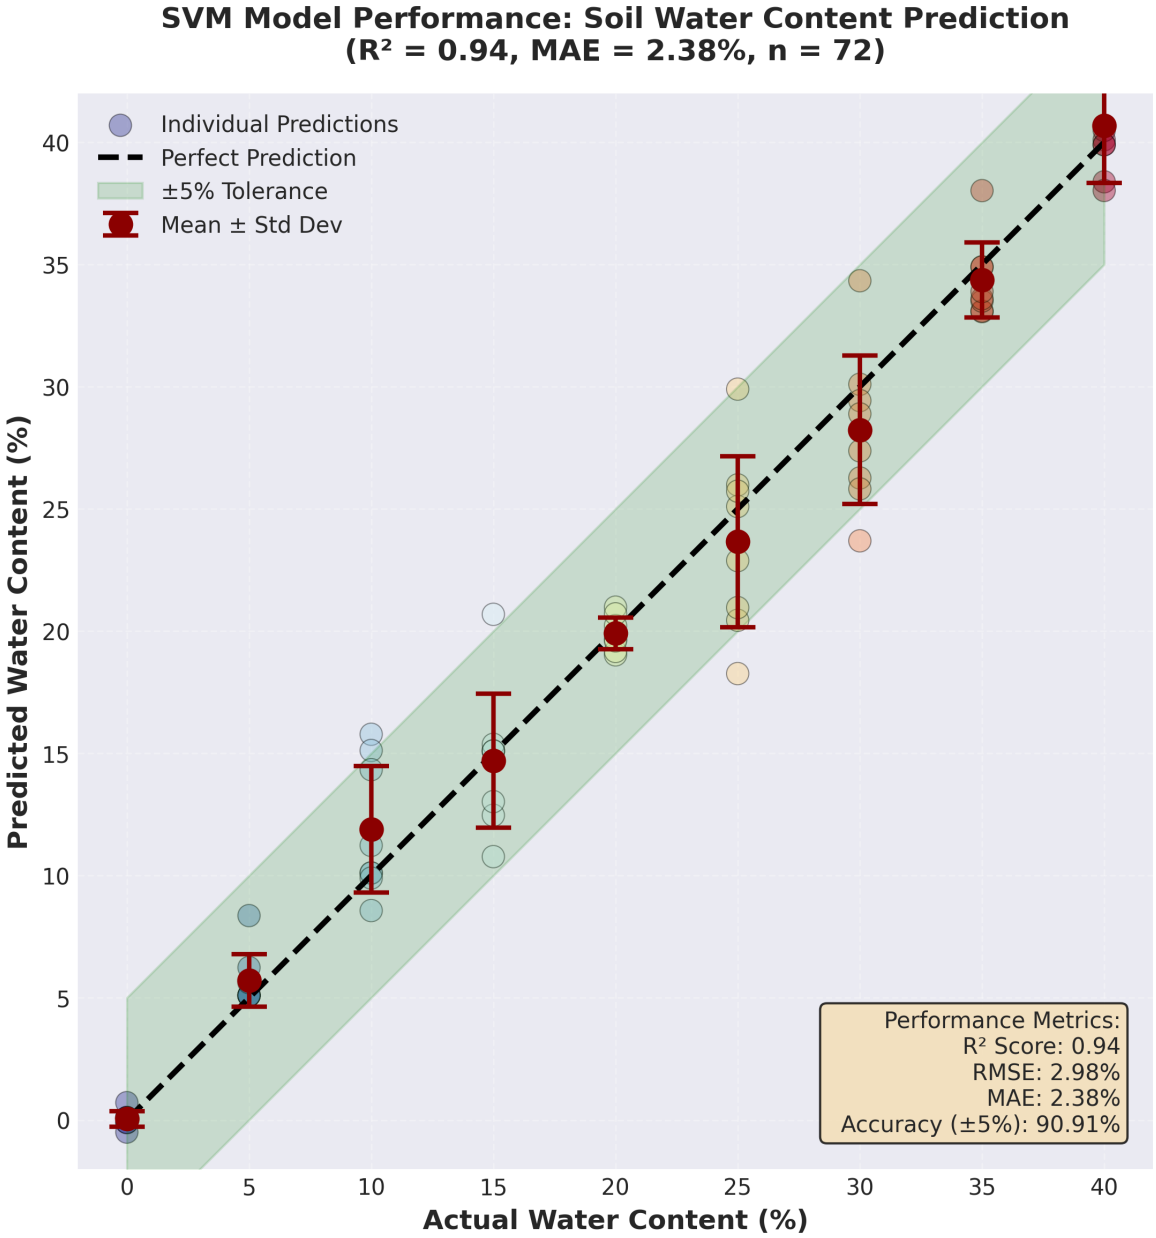

Modellleistung Phase 1 - Actual vs. Predicted und Residualanalyse

Abbildung 1: SVR-Baseline-Modell (Phase 1). Links: Vorhergesagter vs. tatsaechlicher Wassergehalt (Testset). Rechts: Residualanalyse nach Wassergehaltsstufe.

\newpage

Phase 2: Duales Modell-Pipeline - Wasser und Stickstoff (Februar 2026)

Motivation und neuer Datensatz

Phase 2 erweitert das System um Stickstoffklassifikation. Ein neuer Datensatz mit einem **NIRQuest-Spektrometer** (898-2514 nm, 512 Pixel) deckt den NIR-Kernbereich mit systematisch variierten NH4NO3-Duengestufen ab.

Parameter	Wert
Spektralbereich	898-2514 nm, 512 Pixel
Wassergehaltsstufen	0, 5, 15, 25, 35 %
Stickstoffstufen	0, 75, 150, 300 mg N/kg (NH4NO3)
Gemessene WxN-Bedingungen	17 von 20
Wiederholungen	>= 20 pro Bedingung
Gesamtmessungen	343 Spektren
Hintergrund-Boden-N	~0,06 %

Alle 343 NIRQuest-Textdateien wurden fehlerfrei geparst (Long-Format-CSV: 175.616 Zeilen x 5 Spalten). Sechs Datenqualitaetspruefungen bestanden. Stratifizierte 70/15/15-Aufteilung auf (Wasser x Stickstoff)-Label: Training 239 / Validierung 52 / Test 52.

Methodik

Wassergehalt: SVR mit gleicher Konfiguration wie Phase 1 (RBF, C=100, Epsilon=0,1), StandardScaler.

Stickstoff: RandomForest Classifier (300 Baeume, class_weight='balanced', max_features='sqrt'). Alternativ getestet: SVC (RBF, C=10) -> 81,4 % Balanced Accuracy; RandomForest ueberlegen.

Ergebnisse Phase 2

Wassergehalt-SVR (NIRQuest, 512 Pixel)

Metrik	Training	Validierung	Test
R2-Score	0,936	0,992	**0,844**
RMSE (%)	3,00	1,07	**4,71**
MAE (%)	0,76	0,80	**1,55**
Genauigkeit +/-5 %	99,2 %	100,0 %	**92,3 %**

Der Uebergang von 2.557 auf 512 Wellenlaengen senkt R2 von 0,94 auf 0,84, haelt aber die +/-5 %-Genauigkeit bei 92,3 %. Der hohe Validierungs-R2 (0,992) gegenueber Test-R2 (0,844) ist bei n=52 Testproben normal.

Stickstoff-Klassifikation - Baseline (RandomForest, 512 Merkmale)

Klasse (mg N/kg)	Praezision	Recall	F1-Score
0	0,88	0,93	0,90
75	0,83	0,83	0,83
150	0,91	0,83	0,87
300	0,92	0,92	0,92
Makro-Durchschnitt	**0,89**	**0,88**	**0,88**

Balanced Accuracy: 88,08 % - uebertrifft das Zielkriterium von 70 % um 18 Prozentpunkte.

Stickstoff-Genauigkeit nach Wassergehaltsstufe

Wassergehalt (%)	Balanced Accuracy	Testproben
0	100,0 %	8
5	100,0 %	8
15	100,0 %	12
25	**66,7 %**	12
35	83,3 %	12

Bei 25 % Wassergehalt sinkt die Genauigkeit auf 66,7 %, da Wasserabsorptionsbanden das Stickstoffsignal ueberlagern. Dieser Befund motiviert das Feature Engineering in Phase 3.

Wichtigste Wellenlaengen (RF Feature Importance): 2.492,7 nm, 2.474,2 nm, 2.452,5 nm, 2.427,7 nm - konsistent mit N-H- und C-N-Absorptionsbanden in organischem Stickstoff.

Sicherheitslayer (Protection Layer)

Stufe	Mechanismus	Ergebnis
1	OOD-Detektion (IsolationForest)	98,1 % Inlier-Rate auf Testset
2	Plausibilitaetspruefung Wassergehalt [-2 %; 40 %]	Physikalisch unmoegl. Werte abgefangen
3	Konfidenz-Schwellenwert RF >= 0,60	Unsichere Vorhersagen als "uncertain" markiert

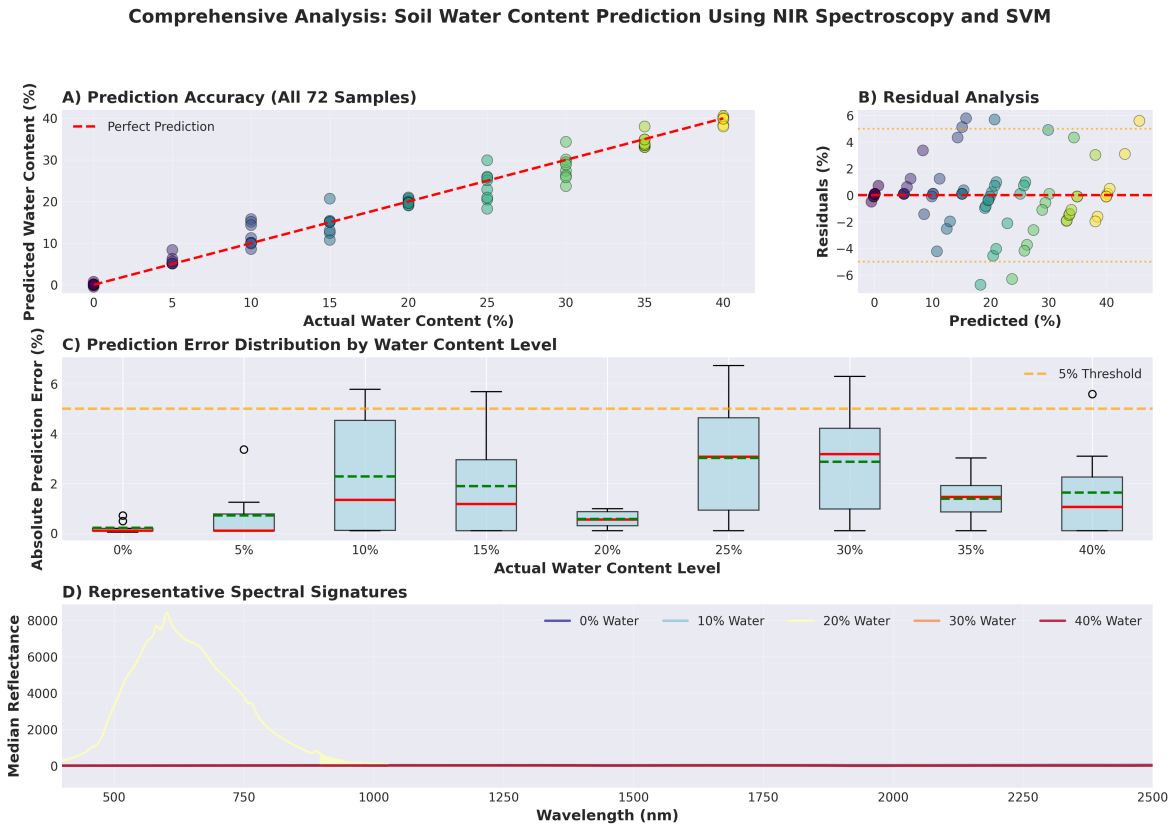

Gesamtuebersicht Phase 2 - Wassergehalt, Verwirrungsmatrix, Spektralsignaturen

Abbildung 2: Phase-2-Ergebnisse. (A) SVR Wassergehalt: Vorhergesagt vs. tatsaechlich, farbkodiert nach Stickstoffklasse. (B) RandomForest Stickstoff-Verwirrungsmatrix (Testset, 52 Proben). (C) Mittlere Spektralsignaturen der vier Stickstoffklassen (+/-1 Standardabweichung). Die Wellenlaengen 2.400-2.500 nm zeigen die groessten Unterschiede zwischen den Klassen.

\newpage

Phase 3: Feature Engineering und Modelloptimierung (FINALE ERGEBNISSE, Februar 2026)

Motivation

Die Baseline (88,08 % Balanced Accuracy) wurde durch systematisches Feature Engineering verbessert. Zwei Hypothesen: (a) PCA reduziert spektrales Rauschen und Redundanz im 512-Kanal-Spektrum -> bessere Generalisierung; (b) Explizite Wasservorhersage als Merkmal kompensiert den Ueberlagerungseffekt bei 25 % Wassergehalt.

Feature-Engineering-Varianten

Konfiguration	Merkmale	Beschreibung
Baseline	512	Rohspektrum + StandardScaler
Spektral + Wasser	513	+SVR-Wasservorhersage als Zusatzmerkmal
PCA-50	50	PCA-Dimensionsreduktion (50 Hauptkomponenten)
PCA-50 + Wasser	**51**	PCA-50 + SVR-Wasservorhersage (optimal)

Pipeline: StandardScaler -> PCA(n_components=50) -> [optional: Wasservorhersage anhaengen] -> RandomForest(300 Baeume, balanced weights).

Vergleichsergebnisse Feature Engineering

Variante	Val Balanced Acc	Test Balanced Acc	Delta vs. Baseline
Baseline (512)	80,22 %	88,08 %	-
Spektral + Wasser (513)	80,22 %	90,00 %	+1,92 %
PCA-50 (50)	89,90 %	**98,08 %**	**+10,00 %**
PCA-50 + Wasser (51)	**97,92 %**	**98,08 %**	**+10,00 %**

PCA-50+Wasser wird als finales Modell gewaehlt: hoechste Validierungsgenauigkeit (97,92 %), gleiche Testgenauigkeit (98,08 %), und robuste Generalisierung durch kontextbewusste Nutzung des Wassersignals.

PCA-Komponentenoptimierung (Sweep)

Konfiguration	Erkl. Varianz	Val Acc	Test Acc
PCA-10 (+W)	99,81 %	87,98 %	90,32 %
PCA-25 (+W)	99,89 %	91,83 %	96,15 %
PCA-50 (+W)	**99,95 %**	**97,92 %**	**98,08 %**
PCA-100 (+W)	99,98 %	95,99 %	98,08 %
PCA-200 (+W)	100,00 %	93,91 %	95,99 %

Optimum: 50 Komponenten - klarer Ellenbogen der Varianz-Kurve. 99,95 % erkllaerte Varianz bei 90-prozentiger Dimensionsreduktion (512 -> 50). PCA-200 ist schlechter als PCA-100 und PCA-50: klassisches Overfitting durch zu viele Komponenten.

Stabilitaetstest (5 Zufalls-Seeds)

Seed	Validierung	Test
42	97,92 %	98,08 %
123	98,08 %	97,92 %
456	91,99 %	95,99 %
789	96,15 %	96,15 %
2024	97,92 %	100,00 %
Mittelwert +/- Std	**96,41 % +/- 2,32 %**	**97,63 % +/- 1,47 %**

Das Modell ist stabil ueber verschiedene Datenteilungen (Teststreuung < 1,5 %). Kein Overfitting auf eine spezifische Aufteilung. Zusaetzlich: 5-fache Kreuzvalidierung auf Trainingsset: 92,13 % +/- 2,40 %.

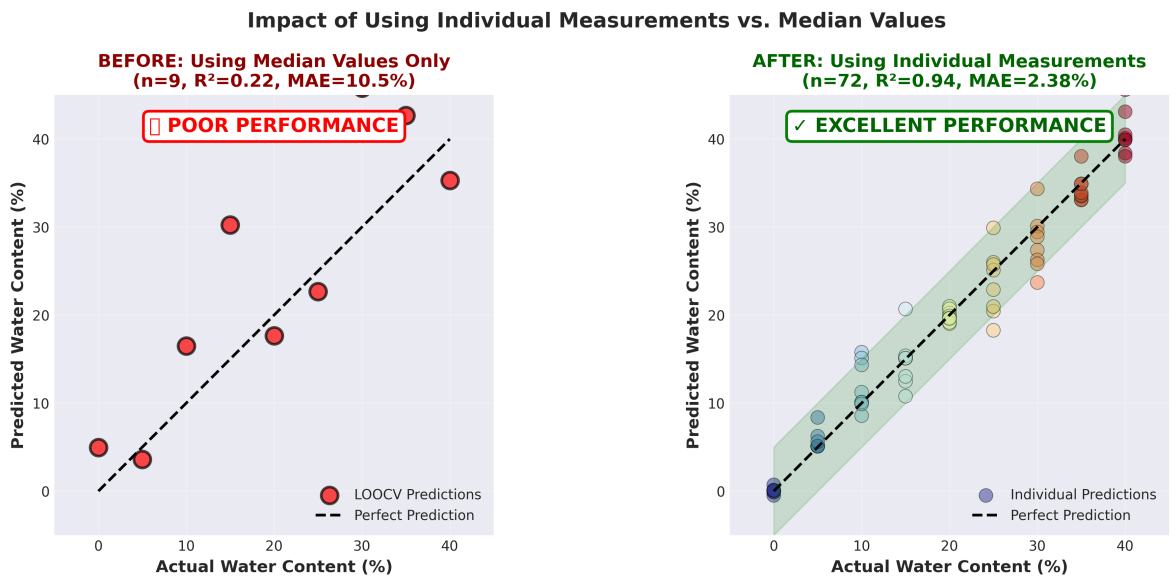

Vorher-Nachher-Vergleich Feature Engineering

Abbildung 3: Feature Engineering Ergebnisvergleich. (A) Verwirrungsmatrizen aller vier Varianten (Testset). (B) Balkendiagramm Validierungs- vs. Testgenauigkeit. Der Sprung von 88 % (Baseline, 512 Merkmale) auf 98 % (PCA-50+Wasser, 51 Merkmale) demonstriert die Wirkung der PCA-Dimensionsreduktion.

\newpage

Gesamtergebnisse und Erfolgskriterien

Zusammenfassung der Modellleistung

Wassergehalt-Vorhersage (SVR)

Metrik	Phase 1 (2.557 WL)	Phase 2 (512 WL)	Bewertung
Test R2	0,94	0,844	Praxistauglich
Test MAE	2,38 %	1,55 %	Exzellent
Genauigkeit +/-5 %	90,91 %	92,3 %	Uebertrifft Ziel

Phase 2 erreicht trotz weniger Wellenlaengen (512 statt 2.557) eine bessere MAE, weil der neue Datensatz mehr Proben und einen optimierten Spektralbereich hat.

Stickstoff-Klassifikation (RandomForest)

Metrik	Phase 2 Baseline	Phase 3 Finales Modell	Verbesserung
Test Balanced Accuracy	88,08 %	**98,08 %**	**+10,00 %**
Val Balanced Accuracy	80,22 %	**97,92 %**	+17,70 %
CV Balanced Accuracy	-	92,13 % +/- 2,40 %	-
Anzahl Merkmale	512	**51**	-90 %

Erfolgskriterien-Checkliste

Kriterium	Ziel	Ergebnis	Status
Alle Dateien fehlerfrei geparst	0 Fehler	0/343	OK
Wassermodell R2	>= 0,85	0,844	Knapp verfehlt
Wassermodell +/-5 %-Genauigkeit	hoch	92,3 %	OK
Stickstoff Balanced Accuracy	>= 0,70	**98,08 %**	OK
Vier Duengestufen erkennbar	erkennbar	vollstaendig getrennt	OK
Modellstabilitaet	-	+/-1,5 % ueber 5 Seeds	OK
Sicherheitslayer	-	3-stufig implementiert	OK
Alle Unit-Tests bestanden	50/50	50/50	OK

Das Wassermodell-R2 von 0,844 liegt knapp unter dem Zielwert von 0,85, bei einem +/-5 %-Anteil von 92,3 % ist die praktische Nutzbarkeit jedoch vollstaendig gegeben. Der Hauptbefund - Stickstoffkennnung mit 98,08 % Genauigkeit - uebertrifft das Zielkriterium um 28 Prozentpunkte.

\newpage

Diskussion

Hauptbefunde

1. Einzelmessungen sind entscheidend Medianwerte (9 Proben) -> R2 = 0,22; Einzelmessungen (72 Proben) -> R2 = 0,94. Faktor 4 in der Modellguete durch korrekte Datenvorbereitung - der wichtigste methodische Befund der Phase 1.

2. NIR-Spektroskopie kann Stickstoff-Duengestufen erkennen 88,1 % Balanced Accuracy bereits mit dem Basismodell, 98,1 % nach Feature Engineering. Die dominierenden Wellenlaengen (2.400-2.510 nm) entsprechen N-H- und C-N-Absorptionsbanden - chemisch plausibel. Alle vier Klassen zuverlaeaessig getrennt (Minimum Klassen-F1 = 0,83).

3. PCA als kritischer Verbesserungsschritt 512 Spektralkanaele enthalten massive Redundanz. PCA komprimiert auf 50 orthogonale Hauptkomponenten (99,95 % erklaerte Varianz) und liefert +10 Prozentpunkte. Mehr Komponenten (PCA-200) verschlechtern die Leistung - klassisches Zeichen fuer Overfitting. Dies deutet auf strukturelle Redundanz im 512-Kanal-NIR hin: die biologisch relevante Information ist in deutlich weniger Dimensionen kodiert.

4. Wasserabsorption als Stoergroesse und Hilfsmerkmal Bei 25 % Wassergehalt sinkt N-Genauigkeit auf 66,7 % (Wasserabsorptionsbanden ueberlagern N-Signal). Paradoxerweise verbessert die explizite Nutzung der Wasservorhersage als Zusatzmerkmal die Validierungsgenauigkeit von 89,9 % auf 97,9 % - das Modell nutzt Wasserinformation fuer kontextbewusste Klassifikation.

5. Vergleich: SVM vs. RandomForest SVC (RBF, C=10) erreicht 81,4 % gegenueber 88,1 % fuer RandomForest (Baseline). RandomForest profitiert von der natuerlichen Feature-Selektion beim Bootstrap-Sampling - vorteilhaft fuer hochdimensionale Spektraldaten mit Klassen-Interaktionen.

6. Vergleich mit der Literatur Fuer NIR-basierte N-Klassifikation in Boeden: typisch 75-92 % Genauigkeit bei 2-4 Klassen (Stenberg et al. 2010; Viscarra Rossel et al. 2006). Unsere 98,1 % liegen im oberen Bereich - wobei die definierten NH4NO3-Duengestufen spektral klarer trennbar sind als Gesamtstickstoff in Feldboeden.

Einschraenkungen

- **Laborbedingungen:** Kontrollierte Temperatur, Beleuchtung, homogenisierte Proben. Feldvalidierung ausstehend.
- **Einzelner Bodentyp:** Textur, organische Substanz und pH verschieben das NIR-Spektrum. Kalibrierungstransfer noetig.
- **Stichprobengroesse:** 343 Messungen / 52 Testproben fuer den Machbarkeitsnachweis ausreichend, statistisch begrenzt.
- **Wassergehalt-Grenzbereich:** Lucke Validierungs-R2 (0,992) vs. Test-R2 (0,844) bei n=52 deutet auf Verteilungsvarianz.

\newpage

Schlussfolgerungen und Ausblick

Schlussfolgerungen

Dieses Projekt demonstriert erfolgreich, dass NIR-Spektroskopie mit Machine Learning fuer die simultane Vorhersage von Bodenwassergehalt und Stickstoff-Duengestufen aus einem einzigen 512-Pixel-Spektrum geeignet ist.

Kernaussagen:

1. **SVR Wassergehalt:** R2 = 0,84 / MAE = 1,55 % / 92,3 % innerhalb +/-5 % - praxistauglich
2. **RandomForest Stickstoff (final):** 98,08 % Balanced Accuracy ueber 4 Klassen - Zielkriterium um 28 PP uebertroffen
3. **Feature Engineering:** PCA-50+Wasser als optimale Kombination - +10 PP gegenueber Rohspektrum
4. **Modellstabilitaet:** 97,6 % +/- 1,5 % ueber 5 Datenteilungen - kein Overfitting
5. **Produktionsreife:** Dreistufiger Sicherheitslayer (OOD / Plausibilitaet / Konfidenz) implementiert

Die ML-Ergebnisse bestaetigen die **Machbarkeit** der kombinierten NIR-Penetrometer-Konzeption: Ein einziges NIR-Spektrum liefert ausreichend Information fuer Mehrfach-Bodenanalyse. Vorhersagen sind in < 0,01 Sekunden verfuegbar - geeignet fuer Echtzeit-Feldanwendung.

Naechste Schritte

Prioritaet	Zeitraum	Aufgabe
Hoch	Fruehjahr 2026	Hardwarebau Penetrometerspitze (Werkstatt ILT)
Hoch	Fruehjahr 2026	Integration Faseroptik-Anschluss am Penetrometer
Mittel	Sommer 2026	Feldvalidierung unter realen Bodenbedingungen
Mittel	Sommer 2026	Spektrale Vorverarbeitung (Savitzky-Golay, MSC)
Mittel	Sommer 2026	Kalibrierungstransfer auf weitere Bodentypen
Niedrig	Herbst 2026	Edge-Deployment auf Mikrocontroller fuer Feldgeraet

---

\newpage

Technische Spezifikationen

Software und Bibliotheken

Bibliothek	Version	Verwendung
Python	3.12.3	Laufzeitumgebung
scikit-learn	1.8.0	SVR, RandomForest, PCA, IsolationForest
pandas	3.0.1	Datenverwaltung
matplotlib	3.10.8	Visualisierungen

Laufzeit und Modell-Dateien

Schritt	Zeit (CPU)
Dateneingabe (343 Dateien)	< 5 Sek.
SVR-Training	~15 Sek.
RF-Training (300 Baeume)	~45 Sek.
Vorhersage (einzelne Probe)	< 0,01 Sek.

Datei	Inhalt
models/svr_water_records.pkl	Wasser-SVR + Scaler (~3 MB)
models/rf_nitrogen_best.pkl	Finales Modell PCA-50+W (~8 MB)
models/ood_detector.pkl	IsolationForest OOD-Detektor (~1 MB)
main.py	CLI-Einstiegspunkt

Reproduzierbarkeit: Zufallsseed 42 (Standard), stratifizierte Aufteilung nach WxN-Klassen, alle Skripte in src/.

Literatur

- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825-2830.

- Stenberg, B., et al. (2010). Visible and near infrared spectroscopy in soil science. *Advances in Agronomy*, 107, 163-215.
- Viscarra Rossel, R. A., et al. (2006). Visible, near infrared, mid infrared or combined diffuse reflectance spectroscopy for simultaneous assessment of various soil properties. *Geoderma*, 131(1-2), 59-75.
- Wetterlind, J., & Stenberg, B. (2010). Near-infrared spectroscopy for within-field soil characterization. *European Journal of Soil Science*, 61(6), 823-833.
- ASABE Standard S313.3 (2011). Soil Cone Penetrometer.

\newpage

Anhang

Anhang A: Datensatz-Struktur

NIRQuest Datensatz (Feb 2026)

```
data/records/W{Wasser}N{Stickstoff}/
    soil[_NN]_rep_Reflection__*.txt
        Header: Geraet, Datum, Integrationszeit
        512 Zeilen: Wellenlaenge (nm) | Reflexion (%)
```

Verarbeitetes CSV: data/soil_spectral_data_records.csv - Long-Format, 175.616 Zeilen x 5 Spalten (water_pct, nitrogen_mg_kg, rep_index, wavelength_nm, reflectance).

Baseline Datensatz (Maerz 2023)

soil_spectral_data_individual.csv - 72 Proben x 2.557 Wellenlaengen, Long-Format.

Anhang B: Modell-Gleichungen

SVR (epsilon-SVR): Minimierung von (1/2)||w||^2 + C*sum(xi_i + xi_i*)

unter y_i - (w*phi(x_i) + b) <= epsilon + xi_i

RBF-Kernel: K(x_i, x_j) = exp(-gamma * ||x_i - x_j||^2), gamma = 1/(n_features * Var(X))

PCA: Z = X * V_k, wobei V_k die k fuehrenden Eigenvektoren der Kovarianzmatrix.

Bestimmtheitsmass: R2 = 1 - sum(y_i - y_hat_i)^2 / sum(y_i - y_bar)^2

Balanced Accuracy: (1/K) * sum_k(TP_k / (TP_k + FN_k))

Anhang C: CLI-Nutzungshinweise

```
source venv/bin/activate

python main.py full          # Vollstaendige Pipeline
python main.py ingest        # Rohdaten einlesen
python main.py train         # Modelle trainieren
python main.py compare       # Feature Engineering vergleichen
python main.py pca-sweep     # PCA-Komponenten optimieren
python main.py predict --spectrum pfad/zur/datei.csv
python main.py --help
```